Einführung in den Compilerbau

Lena Thuy Trang Vo

Wintersemester 2024/25

Inhaltsverzeichnis

Einführung

Schnittstelle zwischen Programmiersprache und Maschine

- Programmiersprache ist gut für den Menschen handhabbar
  - Smalltalk
  - Java
  - C++
- Maschine ist getrimmt auf
  - Ausführungsgeschwindigkeit
  - Preis/Chip-Fläche
  - Energieverbrauch
  - nur selten: leichte Programmierbarkeit

Auswirkung von Compilern

- entscheidet über dem Benutzer zugängliche Rechenleistung
- Compiler entscheiden maßgeblich über die **Effizienz und Leistung** eines Programms auf der Zielhardware
- beeinflussen nicht nur die **Geschwindigkeit der Programmausführung**, sondern auch den **Speicherbedarf** und die **Energieeffizienz**

Programmiersprachen

hohe Ebene: Smalltalk, Java, C++

```
let
    var i : Integer;
in
    i := i + 1;
```

mittlere Ebene: Assembler

```
LOAD    R1, (i)
LOADI   R2, 1
ADD     R1 R1, R2
STORE   R1, (i)
```

niedrige Ebene: Maschinensprache

```
0110000100000110
0111001001000001
1011000100010010
1001000100000110
```

Unterschiedliche Abstraktionsebenen

- auf unteren Ebenen immer **feinere Beschreibung**
- immer näher an Zielmaschine (Hardware)
- Details werden von Compiler hinzugefügt
  - durch verschiedenste Algorithmen
    - Analyse von Programmeigenschaften
    - Verfeinerung der Beschreibung durch Synthese
- Höhere Ebenen **erleichtern die Entwicklung komplexer Logik**, während niedrigere Ebenen **maximale Kontrolle** über die Hardware bieten

Auswirkungen der Zielmaschine

Einfach: Henessy & Patterson DLX

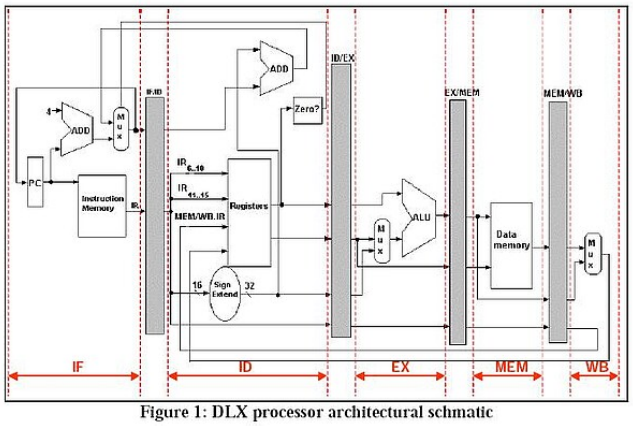

Figure 1: DLX processor architectural schmatic

Abbildung 1: DLX-Prozessor

- ist eine **Reduced Instruction Set Computer** (RISC) Architektur, die auf Einfachheit und Effizienz ausgelegt ist
- basiert auf einem **Load/Store-Design**, bei dem alle Operationen auf Register beschränkt sind mit Ausnahme von Lade- und Speicheroperationen
- die DLX-Architektur verwerndet eine **32-Bit-Datenbreite** und bietet 32 allgemeine Register, die jeweils 32 Bit breit sind
- implementiert eine **fünfstufige Instruktionspipeline**, die aus den Phasen Instruction Fetch (IF), Instruction Decode (ID), Execution (EX), Memory Access (MEM) und Write Back (WB) besteht

Komplizierter: Analog Devices TigerSHARC

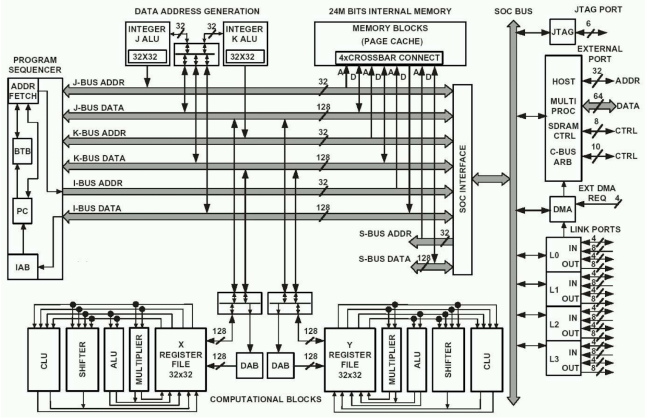

Abbildung 2: Analog Devices TigerSHARC

- ist ein leistungsstarker **digitaler Signalprozessor** (DSP), der für anspruchsvolle Anwendungen entwickelt wurde

- kann bis zu vier Instruktionen pro Taktzyklus ausführenm was eine hohe Parallelität bei der Verarbeitung ermöglicht
- ist für Hochleistungs-Multiprocessing-Anwendungen ausgelegt, wie z.B. Motorsteuerung, Energiemanagement, Prozesssteuerung und Sicherheitssysteme
- Kombination aus **hoher Ausführungsgeschwindigkeit**, **flexibler Datenverarbeitung** und **robuster Speicherverwaltung**

Problematisch: IBM/Sony Cell Processor

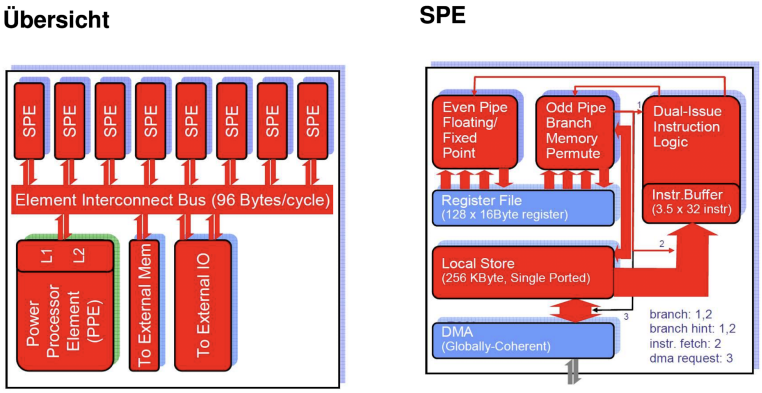

Abbildung 3: IBM/Sony Cell Processor

- ist eine innovative Prozessorarchitektur, die von **IBM**, **Sony** und **Toshiba** entwickelt wurde
- der zentrale Steuerprozessor basiert auf der 64-Bit-PowerPC-Architektur und kann zwei Threads gleichzeitig verarbeiten
- parallele Verarbeitung
- in Ps3

Spezialisierte Anforderungen an CPUs

Je nach Anwendungsgebiet mehr oder weniger wichtig...

- Rechenleistung (hoch/niedrig):
  - Anwendungen wie KI, Gaming oder CAD erfordern hohe Rechenleistung, während einfache Büroanwendungen weniger anspruchsvoll sind
- Datentypen (Gleitkomma, ganzzahlig, Vektoren):
  - wissenschaftliche Berechnungne benötigen oft Gleitkommaoperationen, während Grafikverarbeitung von Vektorenoperationen profitiert
- Operationen (Multiplikationen, MACs):
  - DSPs und Grafikprozessoren nutzen häufig MACs für schnelle Berechnungen in Signalverarbeitung und Rendering
- Speicherbandbreite (parallele Speicherzugriffe):
  - hohe Speicherbandbreite ist entscheidend für Anwendungenm die große Datenmengen verarbeitenm wie Videobearbeitung oder Simulationen

- Energieeffizienz:
  - in mobilen Geräten entscheident, um die Akkulaufzeit zu maximieren
- Platzbedarf (für den Prozessorchip):
  - in eingebetteten Systemen und mobilen Geräten ist der Platzbedarf des Prozessors ein wichtiger Faktor

... können häufig nur durch spezialisierte Prozessoren erfüllt werden

⟶ **benötigen passende Compiler**

Technologie

- Taktfrequenz von Prozessoren nur **mit Mühe steigerbar**
- Trend geht weg von **hochgetakten Einzelprozessoren** hin zu vielen, aber langsameren Prozessoren
- um die Vorteile von Mehrkern-CPUs und GPUs zu nutzen, wurden verschiedene parallele Programmiermodelle entwickelt:
  - **OpenMP:** Mehr-Kern-CPUs
  - **NVidia CUDA:** GPUs
  - **OpenCL:** Heterogene Systeme (GPUs + CPUs, experimentell auch schon FPGAs)
- aber noch wenig abstrakt
  - Entwickler müssen **explizit angeben**, wie Aufgaben parallelisiert werden sollen, was komplex und fehleranfällig sein kann
- keine automatische Parallelisierung!

Anwendungsgebiet: Machine Learning

- Parallelisierung ist besonders wichtig im Bereich des maschinellen Lernens
- Frameworks wie TensorFlow XLA und Glow nutzen parallele Berechnungen, um komplexe Modelle effizienter zu trainieren und auszuführen

Aufbau von Compilern

- Vorgehen: Bearbeitung in **mehreren Phasen**
- Zwischendarstellungen werden verwendet, um Informationen zwischen diesen Phasen auzutauschen

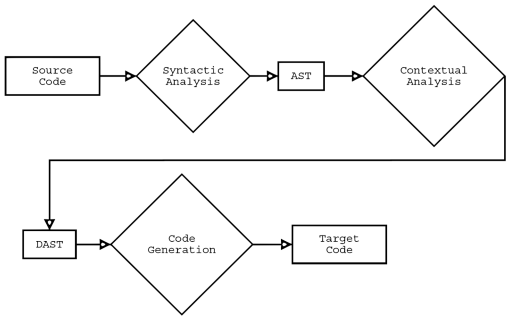

Abbildung 4: Vorgehen

Syntaxanalyse

- folgt auf die lexikalische Analyse und **überprüft**, ob der **Quellcode den Syntaxregeln** der jeweiligen Programmiersprache entspricht
- stellt sicher, dass der Quellcode grammatikalisch korrekt ist
- wenn der Code den Regeln entspricht, wird ein Syntaxbaum erstellt
  - dieser Baum repräsentiert die hierarchische Struktur des Codes und dient als Grundlage für die nachfolgenden Phasen wie die semantische Analyse und Optimierung
  - Baum dient als **Zwischendarstellung für den Informationsaustausch** zwischen den verschiedenen Phasen des Compilers.

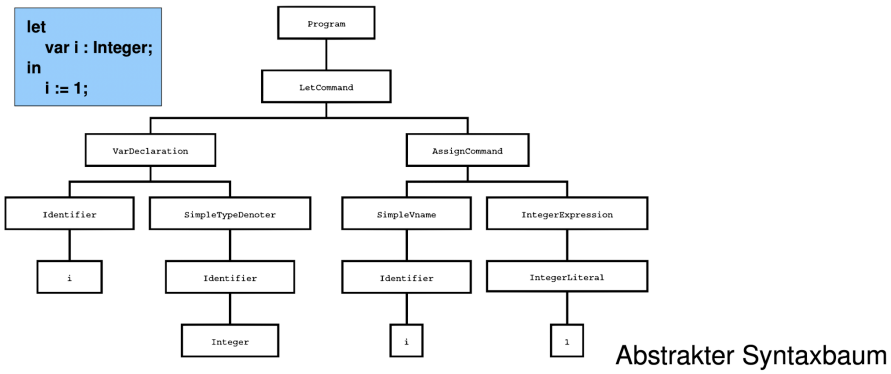

Abbildung 5: Syntaxbaum

Kontextanalyse

- auch als **semantische Analyse** bekannt
- überprüft, ob alle verwendeten Variablen korrekt deklariert wurden
- stellt sicher, dass jede Variable vor ihrer Verwendung definiert ist und dass **keine Mehrfachdeklarationen** im selben Gültigkeitsbereich vorhanden sind
- bestimmt die Datentypen aller Ausdrücke im Programm.
  - Überprüfung von Typkompatibilität bei Operationen und Zuweisungen, um sicherzustellen, dass beispielsweise keine Ganzzahlen mit Zeichenketten addiert werden

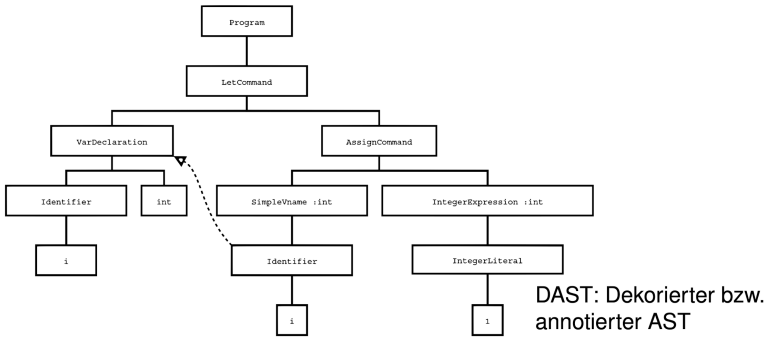

Abbildung 6: DAST

Code-Erzeugung

- Programm ist syntaktisch und kontextuell korrekt
- Übersetzung in Zielsprache
  - Maschinensprache
  - Assembler
  - C
  - andere Hochsprache
- Zuweisung von **DAST-Teilen zu Instruktionen**
- Handhabung von Variablen
  1. Deklaration: Reserviere Speicherplatz für eine Variable
  2. Verwendung: Referenziere immer den zugeordneten Speicherplatz

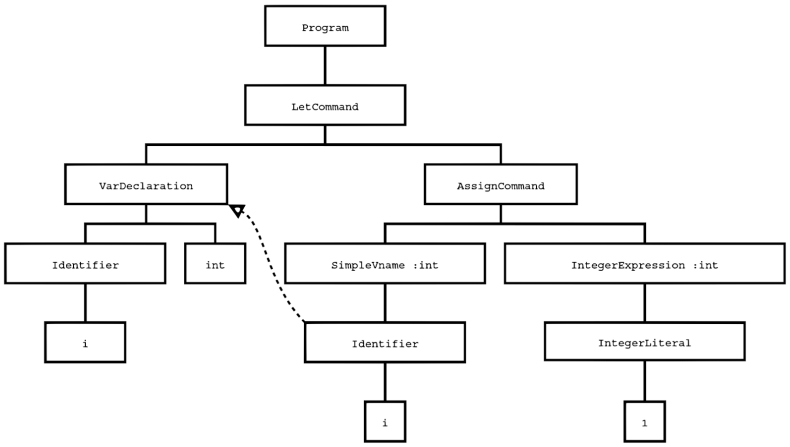


```
0:  PUSH      1          ; Platz fuer 'i' schaffen, Adresse 0[SB]
1:  LOADL     1          ; Wert 1 auf Stack legen
2:  STORE (1) 0[SB]      ; ein Datenwort vom Stack nach Adresse 0[SB] schreiben
3:  POP (0)   1          ; Platz von 'i' wieder aufgeben
4:  HALT                 ; Ausfuehrung beenden
```

Abbildung 7: Code-Erzeugung

Optimierung

Optimierender Compiler

- Front-End: Syntaktische/kontextuelle Analyse
  - überprüft den Quellcode auf **syntaktische** und **semantische Korrektheit**
  - ode wird in eine Intermediate Representation (IR) umgewandelt, die als zentrale Datenstruktur dient

- Middle-End: Transformation von Zwischendarstellungen
  - hier werden maschinenunabhängige Optimierungen auf der IR durchgeführt
  - keine direkte Code-Erzeugung aus Front-End IR
  - verwendet in der Rgel zusätzliche interne Darstellungen
- Back-End: Code-Erzeugung
  - optimierte IR wird in **Maschinencode** oder eine andere **Zielsprache übersetzt**

Hauptzweck eines optimierenden Compilers ist es, den erzeugten Code hinsichtlich **Ausführungszeit, Speicherverbrauch oder Energieeffizienz** zu verbessern.

Beispiele für Optimierung

Constant-Folding

```
x = (2+3) * y          x = 5 * y
```

- konstante Ausdrücke werden zur Compile-Zeit berechnet, um die Laufzeit zu reduzieren

Common-Subexpression Elimination

```
x = 5 * a + b;          t = 5 * a;
y = 5 * a + c;          x = t + b;
                        y = t + c;
```

- identifiziert und eliminiert wiederholte Berechnungen, indem sie das Ergebnis einer Berechnung speichert und wiederverwendet.

Strength Reduction

```
for (i=0; i <= j; ++i) {
    a[i*3] = 42;
}
```

```
int t = 0;
for (i=0; i <= j; ++i) {
    a[t] = 42;
    t = t + 3;
}
```

- ersetzt teure Operationen durch günstigere, um die Effizienz zu steigern

Loop-invariant Code Motion

```
int t;
for (i=0; i <= j; ++i) {
    t = x * y;
    a[i] = t * i;
}
```

```
int t = x * y;
for (i=0; i <= j; ++i) {
   a[i] = t * i;
}
```

- verschiebt Berechnungen, die innerhalb einer Schleife konstant bleiben, aus der Schleife heraus, um sie nur einmal auszuführen.

Syntax

Beschreibt die Satzstruktur von korrekten Programmen

- $n := n + 1$
  - syntaktisch korrektes Statement in Triangle
- Ein Kreis hat zwei Ecken:
  - syntaktisch korrekte Aussage, ist grammatikalisch korrekt, da sie den Regeln der deutschen Satzstruktur folgt, auch wenn sie inhaltlich falsch ist

Kontextuelle Einschränkungen

Definition

Geltungsbereich (Scope)

- Geltungsbereich bestimmt, wo im Programm eine Variable sichtbar und zugänglich ist
- hilft, Namenskollisionen zu vermeiden, indem er es ermöglicht, dass derselbe Name in verschiedenen Teilen des Programms unterschiedliche Bedeutungen hat

Definition

Typüberprüfung

- Beispielsweise muss eine Variable n vor ihrer Verwendung deklariert werden und kompatible Typen haben

Semantik

operationell:

- beschreibt die Bedeutung eines Programms **in Bezug auf die Schritte**, die **während der Programmausführung** ablaufen
- legt fest, wie ein **Programmzustand in einen anderen** übergeht

denotational:

- **bildet Eingaben auf Ausgaben ab** und abstrahiert von den konkreten Ausführungsschritten

Art der Spezifikation

Für alle drei Teile

1. Syntax
2. kontextuelle Einschränkungen
3. Semantik

...gibt es jeweils zwei Spezifikationsarten

- formal
- informal

Definition

Triangle-Spezifikation

- Formale Syntax (reguläre Ausdrücke, EBNF)
- Informale kontextuelle Einschränkungen
- Informale Semantik

Syntax

Eine Sprache ist eine Menge von Zeichenketten aus einem Alphabet.

Wie diese Menge angeben?

1. mathematische Mengennotation
2. reguläre Ausdrücke
3. kontextfreie Grammatik

Syntax durch Mengenbeschreibung

Beispiele für die beschriebenen Zeichenketten:

- $L = \{a, b, c\}$ beschreibt a, b, c
- $L = \{x^n | n > 0\}$ beschreibt $x, xx, xxx...$
- $L = \{x^n y^m | n > 0, m > 0\}$ beschreibt $xxy, xyy, xxxyy...$
- $L = \{x^n y^n | n > 0\}$ beschreibt $xy, xxyy, ...,$ aber z.B. nicht xxy

Offensichtlich keine sonderlich nützliche und gut zu handhabende Spezifikationsform für komplexere Sprachen.

Reguläre Ausdrücke (REs)

- mächtiges Werkzeug zur Beschreibung von Mustern in Zeichenketten
- erweitere Zeichenkette aus dem Alphabet um Operatoren
  - | zeigt Alternative an
  - $*$ zeigt Null oder mehr Vorkommen des vorangehenden Zeichens an
  - ε ist die leere Zeichenkette
  - (...) erlauben die Gruppierung von Teilausdrücken durch Klammerung

Kontextfreie Grammatiken (CFGs)

Eine kontextfreie Grammatik besteht aus

- einer Menge von Terminalsymbolen T aus Alphabet
- einer Menge von Nicht-Terminalsymbolen N
- einem Startsymbol S
- einem Startsymbol $S \in N$
- einer Menge von Produktionen P
  - beschreiben, wie Nicht-Terminalsymbole aus Terminalsymbolen zusammengesetzt sind

Backus-Naur-Form (BNF)

- Produktionen werden als Regeln geschrieben, bei denen ein **Nicht-Terminalsymbol** auf eine Zeichenkette aus **Terminal- und Nicht-Terminalsymbolen abgebildet** wird
- Nicht-Terminal ::= **Zeichenkette**

erweiterte Backus-Naur-Form (EBNF)

- erweitert BNF durch zusätzliche Operatoren, die die Grammatik **kompakter** und **ausdrucksstärker** machen
- ermöglicht die Verwendung von regulären Ausdrücken zur Beschreibung der Produktionen
- asus Terminal und Nicht-Terminalsymbolen
- Nicht-Terminal ::= **RE**

(Mini-)Triangle

- pascal-artige Sprache als Anschauungsobjekt
- Compiler-Quellcode auf Webpage

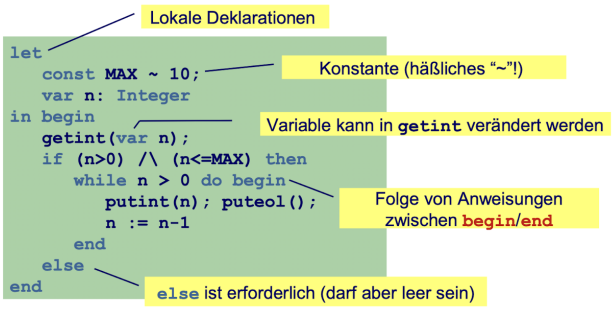

Abbildung 8: Mini-Triangle

Terminologie

Phrase: von einem gegebenen Nicht-Terminalsymbol herleitbare Kette von Terminalsymbolen

Satz: S-Phrase, wobei S das Startsymbol der CFG ist

Beispiel:

```
let                 (1)
  var y : Integer   (2)
in                  (3)
  y := y + 1        (4)
```

- Das gesamte Program ist ein *Satz* der CFG
- Zeile 2 ist eine single-Declaration-Phrase
- Zeile 4 ist eine single-Command-Phrase

Abbildung 9: Beispiel